UNIDAD DIDACTICA 3

GESTIÓN DE DATOS

En esta unidad de trabajo vamos a tratar lo referente a la gestión de datos en entornos de Big Data.

Comenzamos viendo el proceso de ETL, el cual constituye la puerta de entrada más generalmente empleada a la hora de nutrir con datos nuestros sistemas. Aquí estudiaremos tanto sus 3 fases como dos de las herramientas más empleadas como parte del proceso.

A continuación descubriremos la integración de datos, poniendo énfasis en la distinción entre ésta y el mencionando proceso de ETL, ya que están en cierto modo relacionados.

Más adelante daremos un repaso a la normativa de tratamiento de datos, enumerando las distintas leyes vigentes y realizando un análisis algo más detallado del RGPD (a nivel europeo y de aplicación a partir de 2018).

Por último trataremos el concepto de Gobierno de Datos, el cual constituye una supervisión de toda la gestión realizada sobre los datos.

1. ETL

ETL ("Extraer, Transformar, Cargar", del inglés "Extract, Transform, Load"), es el proceso quede forma necesaria es imprescindible realizar si tenemos datos provenientes de una o varias fuentes y queremos enviarlos de forma unificada a un almacenamiento de destino. Como veremos más adelante, primero es necesario adquirirlos desde sus fuentes (extraer),después generalmente es necesario transformarlos de algún modo (transformar) y por último hay que realizar su carga en el ya mencionado almacén de datos.

En muchas ocasiones ETL es confundido con otro proceso o mecanismo en cierto modo relacionado que recibe el nombre de *integración de datos*. Veremos más adelante lo que significa integración de datos, pero vamos a aprovechar ahora para aclarar sus diferencias.

ETL	**Integración de datos**
Extraer desde fuentes, transformar y cargar datos.	Ofrecer una visión unificada de datos que residen en distintas fuentes.
Se produce una copia (modificada) de datos.	En su uso ideal no se realiza ninguna copia sino que los datos siguen residiendo en las fuentes originales.

Es importante destacar que las fuentes de origen a emplear en el proceso de ETL no tienen por qué contener únicamente datos recientes sino que en ocasiones también pueden ser históricos. Por ejemplo, los procesos ETL también se utilizan para integraciones con migraciones desde sistemas heredados. Un posible caso sería migrar los datos de un ERP preexistente a uno nuevo.

Históricamente los destinos más típicos de los procesos ETL han sido los almacenes de datos, sobre todo para un posterior uso OLAP. De este modo se descargan los sistemas OLTP de toda carga analítica y ésta puede realizarse sobre una instantánea de los datos almacenada en un formato directamente preparado para el trabajo analítico.

Sin embargo, con la aparición de muchos otros usos de los datos y sistemas de almacenaje de los mismos, los procesos ETL han comenzado a tener otros destinos. Por ejemplo en ambientes Big Data es muy común que tal destino sea un sistema de ficheros distribuido, como HDFS o Amazon S3.

1.1. Fases de ETL

A continuación vamos a ver cuáles son las 3 fases involucradas en el proceso de ETL.

Veremos aquí un esquema/resumen para que puedas tener una vista general:

- **Extraer (*extract*):**Fase en la que se extraen los datos desde diversas fuentes, incluyendo una validación previa de los mismos.
- **Transformar (*transform*):**Fase en la que se realiza todo el proceso de transformación de los datos para dejarlos en el formato finalmente deseado. Entre otras cosas incluye limpiar datos y crear datos sintéticos como resultado de otros.
- **Cargar (*load*):**Fase en la que finalmente se cargan los datos en el destino final, el cual como hemos dicho suele ser o bien un almacén de datos o un sistema de ficheros distribuido.

1.1.1. Extraer

La primera parte del proceso de ETL es la extracción de datos desde las diversas fuentes en las que estos puedan encontrarse o incluso provenir en forma de flujo (*stream*).

Esta primera parte del proceso es fundamental, ya que de su correcta ejecución depende por completo el éxito del resultado final.

Incluye tanto el acceso a fuentes de datos de entrada como una primera fase de chequeo de los datos para darlos por válidos o en su defecto rechazar los.

Tales fuentes de datos pueden ser de tipo muy variado y con formatos heterogéneos.

- Bases de datos relacionales.
- Almacenes de datos.
- Ficheros en diversos formatos.
- Transacciones que se van produciendo sobre la marcha.
- Logs de servidores web.
- Resultados obtenidos mediante arañas web.
- Mediciones producidas por dispositivos IoT.…

Una de las mayores dificultades de esta fase viene precisamente por la gran variedad de fuentes de datos que podemos encontrar, y la necesidad para integrarse con ellas empleando sus mismos formatos y protocolos. Para los tipos de fuentes más típicas lo común será que la herramienta ETL a utilizar ya sea compatible. Sin embargo en otras ocasiones habrá que realizar algún tipo de desarrollo específico para realizar tal integración. Algunas opciones para ello pueden ser:

1. Conseguir que el sistema en el que está la fuente deje los datos en un formato al que podamos acceder (por ejemplo en ficheros o en una base de datos auxiliar a tal efecto). Programar un intermediario o conector capaz de adquirir los datos según e lprotocolo y formato en el que la fuente los entrega.
2. Hay que tener en cuenta que el proceso de extracción no debe afectar al funcionamiento de los sistemas de los cuales vienen los datos, sobre todo en el caso de los que son transaccionales.

Por ello será importante escoger bien la estrategia a la hora de recibir datos actualizados en el almacén de datos. Puede ser deseable que el almacén de datos esté actualizado a tiempo real según las últimas transacciones. Sin embargo, si eso va a ralentizar el funcionamiento de éstas entonces quizás sea mejor permitir un cierto desfase y que esos datos se obtengan no en tiempo real sino en momentos en los que el sistema transaccional esté menos ocupado (por ejemplo de noche).

Como resultado de esta fase, los datos quedan en un formato válido para que comience la subsiguiente fase de transformación.

1.1.2. Transformar

En la fase de transformación se emplea una serie de reglas sobre los datos extraídos con la intención de prepararlos para ser finalmente cargados en el destino correspondiente.

Durante esta fase nos aseguramos de que al destino sólo van a llegar datos realmente válidos, y que estos estarán en el formato deseado.

Para ello puede ser necesario realizar diversos tipos de transformación, entre los cuales se encuentran los siguientes:

- Seleccionar sólo determinadas columnas o atributos de cada registro.
- Seleccionar sólo determinados registros según si cumplen o no determinada condición.
- Transponer filas en columas o columnas en filas.
- Eliminar datos que resulten estar duplicados.
- Cuando un dato no esté presente, intentar darle valor si puede deducirse a partir del resto de los datos.
- Ordenar los datos según los valores de ciertas columnas si de ese modo se acelera su uso en destino.
- Traducir valores codificados según la nomenclatura o codificación del origen a la que tendrán en destino (por ejemplo traducir de *"Válido"* a *1*).
- Crear nuevos valores derivados de otros (por ejemplo *area = lado1 * lado2*).
- Dividir un atributo en varios (por ejemplo una fecha en año, mes y día).
- Realizar unificaciones de datos que provienen de distintas fuentes.
- Calcular datos agregados (por ejemplo suma de totales o cálculo de medias).
- Comprobar que los registros referenciados por claves externas realmente existen, y quizás realizar algún tipo de denormalización.

La fase de transformación suele ser por lo general la que mayor esfuerzo humano requiere (de comunicación y comprensión), ya que se necesita comprender a la perfección el significado que tienen los datos en las fuentes de origen y el que deben tener en destino. Por ello los expertos encargados del proceso de ETL deben realizar en primer lugar un diseño detallado de las distintas reglas que se van a ir aplicando y en qué orden.

1.1.3. Cargar

La fase de carga del proceso de ETL es con diferencia la más sencilla y liviana, ya que es la única en la que ya podemos decir que la situación está desde un principio bajo control. Ello se debe a que gracias a la fase de transformación los datos ya están en el formato deseado ya que el almacén de destino para los datos es propio. Dado que es propio lo habremos escogido según las necesidades y no tendremos ningún problema para conectarnos a él como sí podía ocurrir con las fuentes en la fase de extracción.

Los destinos de datos pueden ser muy variados:

- Almacenes de datos para uso OLAP.
- Ficheros planos.
- Sistemas OLTP (por ejemplo si migramos de un ERP antiguo a otro nuevo).
- Sistemas de ficheros distribuidos como HDFS o Amazon S3.

Algo muy a tener en cuenta al cargar los datos en destino es decidir cómo interactúan los datos nuevos con los que ya haya almacenados, lo cual dependerá del uso que se les quiera dar y de los requisitos de gobernanza de datos acerca de datos históricos.

Algunas opciones en este sentido son las siguientes:

a) Cargar los datos completos cada vez, eliminando previamente los datos antiguos.
b) Cargar sólo datos nuevos que no afectan a los que ya hay cargados.
c) Cargar datos de forma incremental, lo cual puede implicar la actualización de los que ya hay cargados.

Al margen de todo ello, y también según los requisitos de gobernanza de datos, el almacenaje de destino puede incluir algún mecanismo que le permita guardar un registro histórico de los estados por los que va pasando cada dato, lo cual puede ser muy útil a la hora de auditar la información.

Cuando hay un mecanismo de este tipo, tras actualizar un dato veremos la última versión del mismo, pero podremos acceder al histórico del mismo para comprobar los distintos valores que ha ido teniendo a lo largo del tiempo. Ello permite saber qué valores ha tenido el dato, en qué fecha y hora, e incluso con qué procedencia (usuario, fuente o proceso).

1.2. Herramientas.

A continuación vamos a ver 2 de las herramientas de uso más común en procesos ETL cuando nos encontramos en ambientes de Big Data.

Como vemos aquí tienes una vista general:

- ✔ **Apache Sqoop:** *SQL-to-Hadoop*. Es una herramienta de línea de comandos que nos permite obtener datos desde bases de datos relacionales para transferirlos generalmente a sistemas de ficheros distribuidos.
- ✔ **Apache Flume:**Es un software distribuido que permite obtener datos en *streaming* desde gran cantidad de fuentes no estructuradas o semi estructuradas para transferirlos generalmente a sistemas de ficheros distribuidos.

Ambas forman parte del ecosistema de Hadoop, por lo que fueron en un principio diseñadas para enviar datos a HDFS. Sin embargo, a día de hoy son compatibles con otros almacenamientos distribuidos, como por ejemplo Amazon S3.

1.2.1. Apache Sqoop

Apache Sqoop (cuyo nombre proviene de *SQL-to-Hadoop*) es una herramienta de línea de comandos que forma parte del ecosistema Hadoop y que está diseñada para permitirnos obtener datos desde bases de datos relacionales.

Siendo parte de Hadoop, fue en un principio diseñada para enviar los datos resultantes a HDFS (el sistema de ficheros distribuido de Hadoop). Sin embargo con el tiempo ha ido adquiriendo compatibilidad con otros sistemas muy utilizados en el mundo Big Data, como por ejemplo S3 (la solución en la nube de Amazon).

Sqoop es una herramienta ideal si queremos obtener datos que se encuentran en bases de datos relacionales (Oracle, SQL Server, MySQL, Teradata, Postgres, ...). Puede conectarse con cualquier tipo de base de datos que tenga conectividad JDBC.

Algunas de las principales características de Apache Sqoop son las siguientes:

- Permite importaciones en masa (*bulk*), siendo capaz de obtener tablas individuales o incluso bases de datos completas.
- Paraleliza la transferencia de datos para conseguir un alto rendimiento de lectura desde las fuentes y un uso óptimo del sistema.
- Cuenta con mecanismos para evitar sobrecargar las fuentes.
- Permite realizar mapeados directos de bases de datos relacionales hacia otras herramientas del ecosistema Hadoop, como HBase o Hive.
- Cuenta con interfaz de línea de comandos.
- También permite acceso programático mediante JDBC.
- Aunque no era la intención inicial, también puede conectarse a bases de datos NoSQL como MongoDB o Cassandra.

Para saber más

Puedes ver más información acerca de Apache Sqoop en los siguientes enlaces.

- ➔ Empieza por aquí: Sqoop en la Wikipedia.
- ➔ A continuación te recomendamos que veas esta visión general de Sqoop(en inglés).
- ➔ También puedes acceder a la web oficial de Apache Sqoop (en inglés),dentro de la cual puedes encontrar toda su documentación.
  - ✗ Dentro de la web oficial, te recomendamos que entres en la documentación de Sqoop.
  - ✗ Para ver cómo trabajar con Sqoop desde línea de comandos entra en esta demostración en 5 minutos.

1.2.2. Apache Flume

Apache Flume es un software distribuido que permite obtener y agregar datos en streaming desde gran cantidad de fuentes no estructuradas o semiestructuradas para transferirlos generalmente a sistemas de ficheros distribuidos.

En un principio la idea era que ayudase fundamentalmente a encaminar hacia HDFS ficheros de log (por ejemplo de servidores web), ya que constituyen una fuente muy típica de entrada a Hadoop. Sin embargo en la actualidad permite conectar con muchos otros tipos de fuente, principalmente en *streaming* y basadas en eventos.

Al igual que ocurre con Sqoop, al ser parte de Hadoop fue en un principio diseñado para enviar los datos resultantes a HDFS (el sistema de ficheros distribuido de Hadoop). Sin embargo con el tiempo ha ido adquiriendo compatibilidad con otros sistemas muy utilizados en el mundo Big Data, como por ejemplo Amazon S3.

Se basa en una arquitectura flexible basada en el encaminamiento de flujos de datos a través de sus 3 tipos de componentes (*Source*, *Channel* y *Sink*).

Algunas de las principales características de Apache Flume son las siguientes:

- Está basado en eventos y se adapta a fuentes en *streaming*.
- Permite adquirir flujos de datos desde múltiples canales de entrada de forma simultánea.
- Permite crear topologías para tratar los flujos de datos hasta llegar al resultado final.
- Diseñado para alto ancho de banda y baja latencia.
- Es tolerante a fallos (por ejemplo a errores producidos en las fuentes) e incluye mecanismos de recuperación.

- Permite escalar de un modo casi lineal añadiendo componentes a la topología.

Para saber más

Puedes ver más información acerca de Apache Flume en los siguientes enlaces.

- Empieza por aquí: Flume en la Wikipedia.
- También puedes acceder a la web oficial de Apache Flume (en inglés),dentro de la cual puedes encontrar toda su documentación.
  - Dentro de la web oficial, te recomendamos que entres en la documentación de Flume.
  - En esa documentación es interesante que veas la guía del usuariode Flume.

2. Integración de datos.

La Integración de Datos tiene objetivos similitudes a los que se persiguen en los proceso ETL, y por ello ambos términos suelen confundirse.

Por lo tanto, debemos dejar clara la diferencia desde un primer momento. Mientras que el proceso de ETL busca llevar los datos desde un origen a un destino, el procedimiento de integración busca entregar una visión unificada de los datos a aquellos usuarios o procesos que vayan a utilizarlos (lo que, como veremos, no sólo puede conseguirse mediante procedimiento de copiado).

Podemos ilustrar esa diferencia con dos figuras, una correspondiente a un proceso ETL y otra correspondiente a una integración de datos:

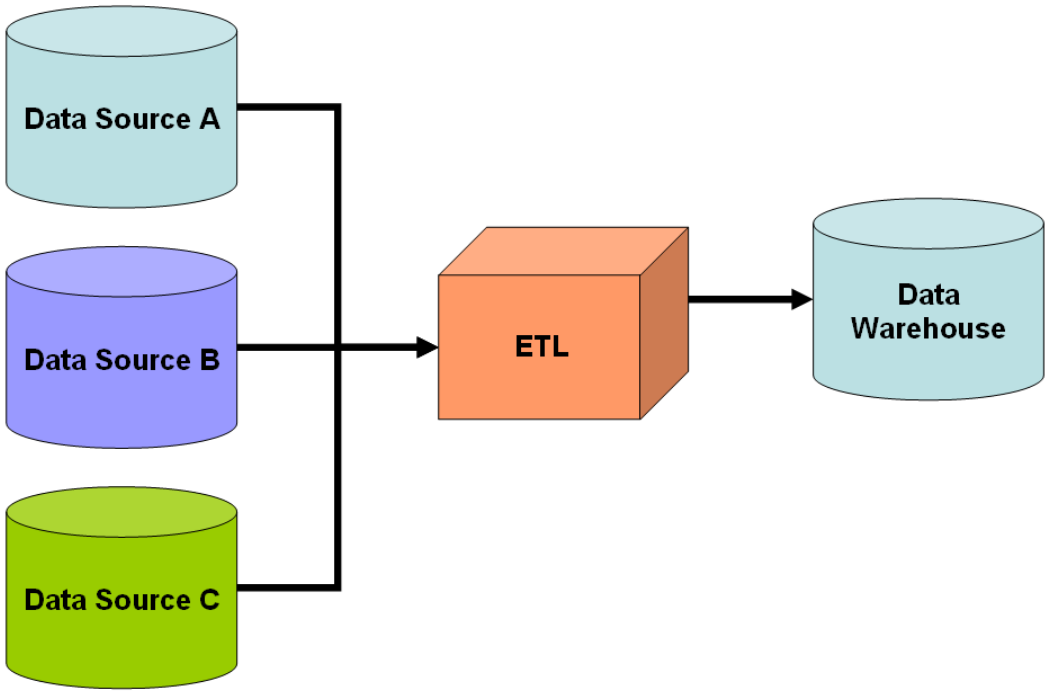

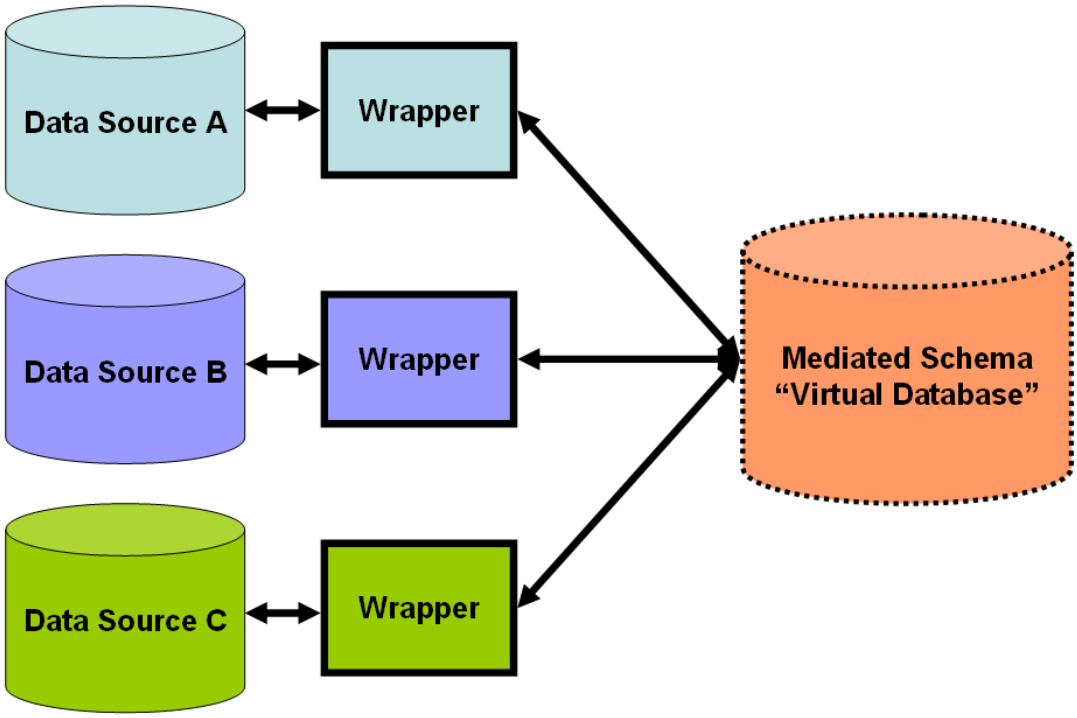

Como podemos observar, en el caso del proceso de Integración de Datos, se diseña una base de datos virtual, la cual cuenta con un esquema mediado (aquel que define cómo queremos ver los datos).

Sin embargo, cuando realizamos una consulta el sistema emplea envoltorios de intermediación (*wrappers*) para acceder realmente a las bases de datos de origen, ya que es en ellas donde residen realmente los datos (siendo la base de datos virtual una mera construcción conceptual).

Para saber más

Puedes ver más información sobre Integración de datos en el siguiente enlace a artículo de la wikipedia. Te lo dejo en inglés. Data integration

2.1. Técnicas de integración de datos.

Hemos visto cómo debería ser una integración de datos en teoría.

Sin embargo, en la práctica se utilizan distintas técnicas para conseguir esos resultados (o similares), las cuales pueden enumerarse según distintos niveles de automatización de la integración (más automatizada cuanto más bajamos en el listado).

- **Integración manual:** Los usuarios operan con los datos accediendo directamente a los sistemas de origen. No existe una visión unificada de los datos.
- **Integración basada en aplicación:** Es una aplicación la que realiza toda la integración, accediendo a los sistemas de origen.Se producen resultados según lo que permita el interfaz de usuario de la aplicación y/o sus capacidades de volcado.
- **Integración basada en :***middleware:*

- ✔ *La lógica de la integración en este caso no está en una aplicación sino en una capa de* la cual facilita datos con algún tipo de transformación a las aplicaciones que a él se conectan.
- ✔ Por lo general ello implica que las aplicaciones aún tienen que participar en la integración. Por ejemplo si una aplicación recibe datos desde más de un *middleware* aún tendrá que fundirlos de algún modo para producir el resultado final.

➢ **Integración virtual (o acceso uniforme a los datos):**

- ✔ Deja los datos en los orígenes y permite acceder a ellos según una vista unificada de los mismos.
- ✔ Según tal visión unificada, accedemos a una base de datos virtual y las consultas se encaminan a los orígenes mediante envoltorios de intermediación (*wrappers*).
- ✔ Ventaja: no hay latencia en la vista final cuando un dato se añade o modifica en el origen.
- ✔ Inconveniente: carga los orígenes cada vez que se hace una consulta.
- ✔ Inconveniente: se pierde la capacidad de realizar algún tipo de gestión de histórico o de versiones de los datos al no emplear almacenamiento propio.

3. Normativa de tratamiento de datos.

1. *Se garantiza el derecho al honor, a la intimidad personal y familiar y a la propia imagen.*
2. *El domicilio es inviolable. Ninguna entrada o registro podrá hacerse en él sin consentimiento del titular o resolución judicial, salvo en caso de flagrante delito.*
3. *Se garantiza el secreto de las comunicaciones y, en especial, de las postales, telegráficas y telefónicas, salvo resolución judicial.*
4. *La ley limitará el uso de la información para garantizar el honor y la intimidad personal y familiar de los ciudadanos y el pleno ejercicio de sus derechos.*

Artículo 18 de la Constitución española de 1978.

Como podemos ver, ya en la **Constitución española de 1978** se recogían, en su artículo 18, derechos acerca del honor, la intimidad y la imagen personal, del mismo modo que se limitaba el uso de la informática para garantizar tales derechos.

Dada la gran importancia de regular estos derechos de un modo adaptado a las nuevas tecnologías, capaces de tratar datos de forma masiva, el 16 de mayo de 2016 se publicó el RGPD el cuál fue de aplicación a partir del 25 de mayo de 2018.

El RGPD era mucho más avanzado que la LOPD que funcionaba en España desde el año1999, por lo que ésta tuvo que ser sustituida en 2018 por la LOPD-GDD, la cual se escribió para estar acorde con el RGPD.

A continuación haremos un análisis de la normativa que se recoge en el RGPD, haciendo especial referencia a su impacto en relación al uso de datos para Big Data.

Para saber más

RGPD: Reglamento General de Protección de Datos

Puedes acceder al fichero PDF con la versión original del RGPD en castellano en el siguiente enlace:

RGPD(2016)

El 23 de mayo de 2018 se publicó una corrección de errores. En el siguiente enlace puedes ver el texto final con la corrección de errores incorporada:

RGPD(con corrección de errores de 2018)

También puedes acceder a información sobre el RGPD a través del siguiente enlace a la Wikipedia:

Reglamento General de Protección de Datos **(wikipedia)**

LOPD-GDD: Ley Orgánica de Protección de Datos Personales y garantía de los derechos digitales.

En el siguiente enlace puedes acceder al PDF de la LOPD-GDD de 2018.

LOPD-GDD(2018)

3.1. Definiciones.

El RGPD incluye un listado de definiciones para clarificar y delimitar diversos conceptos que en él se tratan.

A continuación enumeramos algunos de los más interesantes para el caso de Big Data:

Datos personales:
Toda información sobre una persona física identificada o identificable ("el interesado").Se considerará persona física identificable toda persona cuya identidad pueda determinarse, directa o indirectamente, en particular mediante un identificador, como por ejemplo un nombre, un número de identificación, datos de localización, un identificador online o uno o varios elementos propios de la identidad física, fisiológica, genética, psíquica, económica, cultural o social de dicha persona (art. 4.1 RGPD).

Interesado:
Una persona física identificada o identificable sobre la que los datos personales se están tratando (art. 4.1 RGPD).

Responsable de tratamiento (*controller*):
La persona física o jurídica, autoridad pública, servicio u otro organismo que, solo o junto con otros, determine los fines y medios del tratamiento de datos personales (art.4.7 RGPD).

Encargado del tratamiento (*processor*):
La persona física o jurídica, autoridad pública, servicio u otro organismo que trate datos personales por cuenta del responsable del tratamiento (art. 4.8 RGPD).

Destinatario:

La persona física o jurídica, autoridad pública, servicio u otro organismo al que se comuniquen datos personales, se trate o no de un tercero (art. 4.9 RGPD).

Tercero:
La persona física o jurídica, autoridad pública, servicio u organismo distinto de linteresado, del responsable de tratamiento, del encargado de tratamiento y de las personas autorizadas para tratar los datos personales bajo la autoridad directa del responsable o del encargado (art. 4.10 RGPD).

Delegado de protección de datos (*Data Protection Officer* o *DPO*):
Constituye uno de los elementos claves del RGPD, y un garante del cumplimiento de la normativa de la protección de datos en las organizaciones, sin sustituir las funciones que desarrollan las Autoridades de Control.

Tratamiento:
Cualquier operación o conjunto de operaciones realizadas sobre datos personales o conjuntos de datos personales, ya sea por procedimientos automatizados o no, como la recogida, registro, organización, estructuración, conservación, adaptación o modificación, extracción, consulta, utilización, comunicación por transmisión, difusión o cualquier otra forma de habilitación de acceso, cotejo o interconexión, limitación, supresión o destrucción (art. 4.2 RGPD).

Elaboración de perfiles:
Toda forma de tratamiento automatizado de datos personales consistente en utilizar datos personales para evaluar determinados aspectos personales de una persona física, en particular para analizar o predecir aspectos relativos al rendimiento profesional, situación económica, salud, preferencias personales, intereses, fiabilidad, comportamiento, ubicación o movimientos de dicha persona física (art. 4.4 RGPD).

Consentimiento del interesado:
Toda manifestación de voluntad libre, específica, informada e inequívoca por la que el interesado acepta, ya sea mediante una declaración o una clara acción afirmativa, el tratamiento de datos personales que le conciernen (art. 4.11 RGPD).

3.2. Ámbito de aplicación y bases legales.

El RGPD tiene aplicación sobre el tratamiento automatizado de datos personales que forman parte de un fichero o de un sistema.

Los artículos 2 y 3 del RGPD tienen en cuenta una doble visión en relación a su **ámbito de aplicación**:

- **Ámbito subjetivo:**
  Se aplica tanto a los responsables como a los encargados del tratamiento. No se limita a ciertas áreas de aplicación (como pudieran ser por ejemplo lo personal o lo doméstico).

- **Ámbito territorial:**
  Aplica si los responsables o encargados están establecidos en la UE. También aplica si los interesados se encuentran en el territorio de la UE, aunque no lo estén los responsable o encargados, cuando el tratamiento se destine a ofrecer bienes o servicios a los interesados o al control de su comportamiento.

En los artículos 6 al 8 del RGPD se establecen las **bases legales** para poder tratar datos personales.

La condición básica necesaria para ello es que el interesado **dé su consentimiento** para utilizar sus datos. En tal caso, el responsable debe ser capaz de demostrar que el consentimiento ha sido dado libremente por el interesado, y la solicitud de consentimiento debe ser claramente perceptible.

Existen, sin embargo, algunos casos excepcionales en los que pueden tratarse datos personales sin consentimiento explícito de los interesados. En concreto cuando tal tratamiento sea necesario para:

- Ejecutar o negociar un contrato con el interesado.
- Cumplir con una obligación legal.
- Proteger los intereses vitales del interesado o de otra persona cuando el interesado sea incapaz de dar su consentimiento.
- El cumplimiento de una misión realizada en interés público o en el ejercicio de poder público.
- La satisfacción de los intereses legítimos (pero sujetos a los derechos y libertades fundamentales).

También existen casos de "interés legítimo" en los que se considera que pueden tratarse datos personales (por ejemplo para prevención del fraude o cuestiones de seguridad de la red o de la información). En tales casos el responsable debe informar al interesado de que se esta realizando un tratamiento en base a tal interés legítimo.

3.3. Derecho de los interesados.

Con la RGPD los interesados siguen manteniendo los derechos ARCO (acceso, rectificación, cancelación y oposición) que ya se contemplaban en anteriores normativas, pero ahora en una versión más completa.

En concreto, los interesados tienen los siguientes derechos en relación al tratamiento de sus datos:

Derecho de acceso: los interesados tienen derecho a obtener copias de sus datos personales, junto con los detalles principales sobre cómo se tratan los datos.

Derecho de rectificación: los interesados tienen el derecho a exigir la rectificación de sus datos personales, sin dilaciones indebidas y el derecho a completar los datos personales que sean incompletos.

Derecho al olvido: los interesados tienen derecho a que sus datos personales sean suprimidos del fichero o sistema.

Derecho de limitación: los interesados tienen derecho a impedir tratamientos adicionales.

Derecho a la portabilidad: los interesados tienen derecho a exigir que sus datos sean proporcionados en un formato de “uso común y lectura por equipos y maquinas” para poder ser transmitidos a otro responsable.

Derecho a la notificación: los interesados tienen derecho a ser notificados por el responsable ante cualquier rectificación, supresión y limitación salvo que le sea imposible o exija un esfuerzo desproporcionado.

Además, los responsables quedan obligados a ser más transparentes con los interesados. En concreto, los interesados deben recibir información de cómo se tratan sus datos, incluyendo:

- La identidad del responsable e información de contacto.
- También la identidad de cualquier delegado de protección de datos.
- Las finalidades y bases legales para su tratamiento.
- Cualquier “interés legítimo” que sea la base del tratamiento.
- Cualquier transferencia internacional y garantías aplicables.
- El período de retención o los criterios para su determinación.
- El derecho a la portabilidad de datos y los derechos de oposición al tratamiento, de requerir la limitación y de retirar el consentimiento al tratamiento.
- El derecho a reclamar ante una autoridad de control.
- Cualquier requisito legal o contractual para proporcionar datos, así como las consecuencias de no proporcionarlos.

3.4. Gobierno y rendición de cuentas.

A partir de la puesta en funcionamiento del RGPD, los responsables están obligados a:

- Garantizar su cumplimiento.
- Estar en condiciones de demostrarlo.

Aparte, los responsables están obligados a implementar la protección de datos:

- Por diseño (*privacy by design*).
- Por defecto (*privacy by default*).

En concreto deben tomar las siguiente **medidas**:

- Emplear políticas de protección de datos.
- Emplear códigos de conducta.
- Emplear mecanismos de certificación.

Usarán para ello las siguientes **técnicas** (entre otras):

- **Seudonimización de datos:** de modo que no se pueda reconocer la identidad de una persona sin utilizar información adicional.
- **Minimización de datos:** sólo tratar los datos personales que sean necesarios para la finalidad correspondiente.

Además, los responsables deben:

- Antes de comenzar con el tratamiento de los datos, realizar una evaluación del impacto de las actividades que supongan riesgos importantes para los derechos de los interesados.
- Designar un delegado de protección de datos (DPO):
  - ✗ son autoridades u organismos públicoso
  - ✗ realizan observación habitual y sistemática de interesados a gran escala (BigData)
  - ✗ o tratan datos sensibles a gran escala.
- Mantener registros (documentación) de las actividades de tratamiento que contengan cierta información requerida (fines de tratamiento, descripción de las categorías de los interesados, datos personales, destinatarios, las medidas técnicas y organizativas, y cualquier transferencia de datos a terceros países).

3.5. Obligaciones de los encargados del tratamiento.

El RGPD impone una serie de **requisitos para los contratos** entre los responsables de tratamiento de datos y los encargados designados para ello:

- Un responsable sólo puede encargar un tratamiento de datos a quien cumpla con garantías técnicas y organizativas para cumplir con el RGPD.
- Debe existir un contrato escrito entre el responsable y el encargado.

Tales **contratos deben estipular** lo siguiente:

- El encargado únicamente tratará los datos personales de acuerdo con las instrucciones del responsable.
- El encargado debe asegurar que su personal está sujeto a una obligación de confidencialidad.
- El encargado debe implementar las medidas técnicas y organizativas adecuadas para garantizar un nivel de seguridad de los datos personales apropiado al riesgo.
- El encargado no puede subcontratar el tratamiento de datos personales sin la autorización previa y por escrito del responsable.
- Cualquier contrato entre un encargado y un subencargado debe proporcionar las mismas obligaciones de protección de datos que las previstas en el contrato con el responsable.
- El encargado debe asistir al responsable en garantizar el cumplimiento de las obligaciones de seguridad, la evaluación de impacto de protección de datos y la consulta previa a la Autoridad de Protección de Datos para el tratamiento de datos de alto riesgo.
- El encargado debe suprimir o devolver los datos personales cuando el tratamiento se haya completado.
- El encargado debe proporcionar al responsable toda la información necesaria para demostrar el cumplimiento, así como permitir y contribuir a la realización de auditorías.

3.6. Seguridad de los datos.

Como ya hemos visto, el RGPD obliga a los responsables y encargados a aplicar las medidas técnicas y organizativas de seguridad apropiadas para garantizar un nivel adecuado de protección de los datos personales.

Las **medidas de seguridad** deben incluir:

- La seudonimización de los datos personales.
- El cifrado de datos personales.
- La capacidad de restaurar los datos personales de forma rápida.
- La implementación de procesos de verificación y evaluación.

El RGPD también obliga a la notificación de la violación de seguridad de los datos personales:

- Los responsables deben notificar las violaciones de la seguridad de los datos personales a la autoridad de control pertinente sin dilación indebida (cuando sea posible, dentro de las 72 horas posteriores a la detección de la violación), a menos que sea improbable que dicha violación de la seguridad constituya un riesgo para los derechos y libertades de los interesados.
- Los responsables deben notificar a los interesados afectados por la violación de sus datos personales cuando suponga un alto riesgo para los derechos y libertades de los interesados.
- Los encargados deben informar sobre las violaciones de la seguridad de los datos personales a los responsables sin dilación indebida y en todos los casos.

3.7. Otros aspectos de la normativa.

El RGPD es muy extenso, por lo que no cubriremos aquí todo lo que incluye.

En el caso de que el alumno necesite realizar actividades con la seguridad de que cumple con la legislación, deberá atender a los siguientes documentos legales:

- Reglamento General de Protección de Datos (RGPD) (con corrección de errores de 2018).
- Ley Orgánica de Protección de Datos Personales y garantía de los derechos digitales (LOPD-GDD).

En concreto, no quedan aquí cubiertos pero pueden ser interesantes los artículos del RGPD:

- Artículos 40 a 43, acerca de los **códigos de conducta** y la **acreditación de certificaciones** para demostrar el cumplimiento de las normas.
- Artículos 44 a 50, acerca de las **transferencias internacionales de datos**.
- Artículos 51 a 76, acerca de la **supervisión por las autoridades de protección de datos**.
- Artículos 77 a 84, acerca de los posibles **recursos** así como las potenciales **responsabilidades y sanciones**.

4. Gobierno de datos.

Ya hemos visto la normativa relativa al tratamiento de datos, analizando en concreto el RGPD vigente a partir de 2018.

A continuación queda hablar del **Gobierno de Datos**, que abarca una gran variedad de aspectos relacionados con todo el ciclo de vida del dato, desde que es producido hasta que es eliminado del sistema.

Podemos definir el Gobierno de Datos como el ejercicio de control y autoridad y comunicación sobre la gestión realizada de los datos, con la finalidad de asegurar que tal gestión es correcta de acuerdo con las políticas y las mejores prácticas.

En este sentido, el Gobierno de Datos incluye:

- Planificación.
- Ejecución.
- Seguimiento.

Dada la especial relación entre el Gobierno de Datos y la Gestión de Datos, merece la pena realizar aquí la **distinción entre ambos**:

- La **Gestión de Datos** se realiza para asegurar que la organización obtiene valor de los datos.
- El **Gobierno de Datos** se realiza para supervisar la Gestión de Datos, asegurándose de que la gestión es la correcta (cómo se toman las decisiones y cómo se comportan personas y procesos en relación con los datos).

4.1. Objetivos del gobierno de datos.

El Gobierno de Datos tiene los siguientes **objetivos generales**:

- Facilitar a las organizaciones la gestión de sus **datos** como los **activos** que son.
- Definir, implementar y comunicar, en relación a los datos:
  - ✔ Principios.

- ✔ Políticas.
- ✔ Procedimientos.
- ✔ Métricas.
- ✔ Herramientas.
- ✔ Responsabilidades.

- Monitorizar y guiar el cumplimiento de las políticas definidas respecto a gestión de los datos.

También podemos considerar los siguientes objetivos, esta vez **enfocados por áreas**:

- Realizar una gestión general de riesgos respecto a posibles incidentes.
- Asegurar la seguridad de los datos.
- Asegurar la privacidad de los datos.
- Asegurar el cumplimiento de las normativas.
- Asegurar la calidad de los datos.
- Asegurar la correcta gestión de metadatos.
- Conseguir procesos eficaces.
- Asegurar que el ciclo de vida de los datos es claro y está controlado.

4.2. Marco de referencia.

El Gobierno de Datos está presente en gran cantidad de actividades relacionadas con las gestión de los datos. Algunos autores llaman a estas actividades el marco de referencia del Gobierno de Datos:

Modelado y Diseño de Datos:
Modelado lógico de datos y cómo se va a implementar en la organización.
Almacenamiento y Operación de Datos:

Almacenamiento de datos, mecanismos de despliegue y administración de procesos decarga.

Seguridad de Datos:
Diseño y desarrollo de políticas, estándares, auditoría de la seguridad y cumplimiento regulatorio.

Integración e Interoperabilidad de Datos:
Diseño e implementación de arquitecturas y estándares de interoperabilidad e integración de datos.

Gestión de Documentos y Contenido:
Políticas y actividades para la documentación de los datos a lo largo de su ciclo de vida.

Datos maestros y de referencia:
Definición de requisitos y modelos de datos maestros críticos para la organización.

Data Warehousing & Business Intelligence:
Definición de arquitecturas de Almacenes de Datos y sistemas de reportado para asegurar el uso correcto de los datos cuando se emplean para Inteligencia de Negocio.

Metadatos:
Definición del modelo de metadatos, incluyendo tanto su descripción técnica como de negocio.

Calidad de Datos:
Perfilado de datos, políticas, guías de calidad de datos y monitorización.

Arquitectura de Datos:
Diseño de la estructura lógica y física de los sistemas que van a manejar los datos.

4.3. Roles.

En relación a Gobierno de Dato existen diversos roles a desempeñar, siendo claves los siguientes:

- **Chief Data Officer (CDO):**

  Perfil ejecutivo con función transversal (negocio e IT). Junto con el consejo de gobierno define la estrategia de datos y cómo será la gestión de los mismos. Responsable del modelo de datos. Asesora y supervisa.

- **Oficina de Gobierno del Dato:**

  Ayuda y asiste al CDO en sus funciones (redacción de políticas, medidas de mejora y calidad, coordinación con IT, ...).

- **Data Owners (propietarios del dato):**

  Perfil de negocio. Responsables de los departamentos que usan/producen los datos. Deben definir los objetivos de calidad de los datos. Suele haber un *data owner* por dominio o departamento.

- **Data Stewards (administradores del dato):**

  Perfil de negocio. Responsables de implementar las políticas y procesos definidos. Identifican problemas y necesidades. Suele haber entre 1 y 3 *data steward* por dominio.

- **Data Custodians (custodios del dato):**

  Perfil IT. Atienden las peticiones de tecnología de los propietarios de los datos. Son el punto de contacto del CDO con la tecnología. Suele haber un *data custodian* por sistema.